


Model QSPR do przewidywania LogK_{da}

Adsorpcja zanieczyszczeń organicznych na powierzchni polipropylenu (PP)

Model końcowy: MLR {logD, $\varepsilon\beta$ }

Modele porównawcze: KNN i SVR




Cel i kontekst projektu

Problem

PP może sorbować hydrofobowe zanieczyszczenia organiczne. Eksperymentalne LogKda są kosztowne i dostępne dla ograniczonej liczby związków. QSPR pozwala przewidywać LogKda na podstawie deskryptorów struktury.

Odpowiedź modelu

EXP LogKda — miara adsorpcji związku na PP. Wyższa wartość oznacza silniejszą przewidywaną adsorpcję.




Formalnie jest to QSPR, bo modelowana jest właściwość fizykochemiczna, nie aktywność biologiczna.

Dane wejściowe i podział zbioru

Zbiór	Liczba	Rola w modelowaniu
TS	25	kalibracja i walidacja wewnętrzna LOO-CV
VS	10	walidacja zewnętrzna modelu
EXT	2	true external validation: naftalen i nitrobenzen

Deskryptory dostępne dla true external validation

Związek	logD	Mw'	$\epsilon\alpha$	$\epsilon\beta$	V'	π
Naphthalene	3.30	1.281	0.255	0.296	1.109	1.241
Nitrobenzene	1.85	1.231	0.291	0.327	0.738	0.896



Użyto wartości EXT z pliku True external validation, nie wartości EXT z arkusza Excel.

Strategia doboru deskryptorów dla KNN i SVR

Deskryptory dla KNN/SVR ograniczono do zmiennych dostępnych również dla naftalenu i nitrobenzenu.

Dobór wykonano na TS przez LOO-CV; VS i EXT traktowano jako testy predykcji.

Unikano dużych zestawów deskryptorów, bo $n_{TS} = 25$ i ryzyko przeuczenia jest wysokie.

Model	Wybrany zestaw	Hiperparametry	Uzasadnienie
MLR	$\log D, \epsilon\beta$	brak	interpretowalny model liniowy
KNN	$\log D$	$k=2$, distance	odległościowy model lokalny; mały zestaw deskryptorów
SVR	$\log D, Mw', \pi$	RBF, $C=10$, $\epsilon=0.10$, $\gamma=0.1$	nieliniowość + hydrofobowość, rozmiar i π

Wniosek metodologiczny

KNN i SVR są modelami porównawczymi. Ich celem jest sprawdzenie, czy model nieliniowy daje przewagę nad prostym, interpretowalnym MLR.


Model końcowy MLR: równanie i sens chemiczny

$$\text{LogKda} = 6.378 + 0.734 \cdot \log D - 17.853 \cdot \varepsilon\beta$$

Deskryptor	Kierunek	Interpretacja
logD	+	większa hydrofobowość zwiększa adsorpcję na PP
$\varepsilon\beta$	-	cechy polarne/akceptorowe obniżają preferencję dla PP

Kontrola współliniowości



$r(\log D, \varepsilon\beta) = 0.358$; $VIF \approx 1.15$. Deskryptory nie są redundantne, więc MLR jest stabilny interpretacyjnie.



To jest główny argument za MLR: model wyjaśnia zjawisko, a nie tylko dopasowuje liczby.




Porównanie jakości modeli

Model	Deskryptory	R ² TS	Q ² LOO	Q ² EXT	RMSECV	RMSEP
MLR	logD, εβ	0.918	0.877	0.980	0.526	0.217
KNN	logD	0.987	0.883	0.951	0.513	0.341
SVR	logD, Mw', π	0.987	0.943	0.948	0.359	0.352





MLR ma najniższy RMSEP na VS i bardzo dobrą stabilność LOO-CV przy najmniejszej złożoności.

Predicted vs observed: trzy modele



Wszystkie modele odtwarzają trend, ale MLR zachowuje najlepszą równowagę między predykcją VS i możliwością interpretacji.



Diagnostyka modelu MLR



Reszty nie pokazują silnego trendu systematycznego, ale model ma ograniczenie dla związków, których adsorpcji nie wyjaśnia sama hydrofobowość i $\epsilon\beta$.

Największa reszta: Trimethoprim, lecz bez przekroczenia typowego progu ± 3 w Williams plot.

Dziedzina stosowalności modelu końcowego




$h^* = 0.36$; oba związki EXT mają leverage poniżej progu.

Naftalen i nitrobenzen mieszczą się w zakresie $\log D$ oraz $\epsilon\beta$ zbioru uczącego.

Domena dotyczy podobnych związków organicznych; modelu nie należy ekstrapolować poza tę przestrzeń.

True external validation



Związek	Ref.	MLR pred.	AE MLR	KNN pred.	SVR pred.
Naphthalene	3.70	3.517	0.183	3.258	3.576
Nitrobenzene	2.50	1.899	0.601	1.224	3.174

Interpretacja MLR

Naftalen: bardzo dobra zgodność z wartością referencyjną.


Nitrobenzen: wyraźne niedoszacowanie — ograniczenie modelu dla bardziej polarnego nitroaromatu.

EXT potwierdza użyteczność modelu, ale nie pełną uniwersalność.

$$AE = |LogKda_{pred} - LogKda_{ref}|$$

Dlaczego MLR pozostaje modelem końcowym?

Najniższy błąd predykcji zewnętrznej: RMSEP = 0.217 dla VS.
Tylko dwa deskryptory i brak istotnej współliniowości.
Zgodny z zasadami QSAR/QSPR: jawne równanie,
interpretowalność, walidacja, dziedzina stosowalności.
KNN i SVR są konkurencyjne statystycznie, ale są mniej
transparentne i bardziej wrażliwe na dobór hiperparametrów.



Model końcowy nie został wybrany dlatego, że ma najwyższe R^2 . Został wybrany dlatego, że ma najlepszy kompromis: predykcja + prostota + sens chemiczny.

Wnioski i ograniczenia

Wnioski

Najlepszym modelem końcowym jest MLR {logD, $\epsilon\beta$ }.
KNN i SVR potwierdzają, że logD jest dominującym czynnikiem adsorpcji.
True external validation jest dobra dla naftalenu, ale słabsza dla nitrobenzenu.

Ograniczenia

Mały zbiór danych: TS = 25, VS = 10.
Model z dwoma deskryptorami nie opisuje wszystkich mechanizmów adsorpcji.
Nitrobenzen pokazuje ryzyko błędu dla bardziej polarnych struktur.

Gotowa obrona

„Wybrałem MLR, bo w małym zbiorze QSPR prosty model z chemicznie uzasadnionymi deskryptorami jest bezpieczniejszy niż bardziej elastyczny model nieliniowy. KNN i SVR są użyteczne porównawczo, ale nie dają lepszego kompromisu między predykcją i interpretowalnością.”

Źródła danych: data_qsar_pls_extended.xlsx; True external validation.pdf; instrukcje projektu i wytyczne do prezentacji.