




MODELOWANIE QSAR / QSPR

Model QSPR przewidujący adsorpcję zanieczyszczeń organicznych na polipropylenie (PP)

Współczynnik LogK_{da}

Po co przewidywać adsorpcję na mikroplastiku?

Problem. Mikroplastiki adsorbują na powierzchni zanieczyszczenia organiczne i przenoszą je, działając jak ich nośnik.

Co przewidujemy. LogKda — miara powinowactwa związku do polipropylenu.

Cel modelowania QSPR. Przewidzieć LogKda na podstawie obliczeniowych deskryptorów struktury — bez żmudnych pomiarów dla każdego związku osobno.

Pytanie badawcze

„Czy ze struktury związku można wiarygodnie przewidzieć, jak silnie zaadsorbuje się on na polipropylenie?”

- 1** **Struktura związku** — deskryptory LSER
- 2** **Model QSPR** — liniowa zależność
- 3** **Predykcja LogKda** — dla nowych związków

Dane: 35 związków, 6 deskryptorów LSER

35

Związki

organiczne, LogKda 0,59–7,0

6

Deskryptory

z 1998 dostępnych (LSER)

~1990

Odrzucono

deskryptorów PaDEL

70:30

Podział

uczący 24 / testowy 11




Dlaczego tylko 6 deskryptorów?

Przy $n = 35$ obiektach użycie ~1990 deskryptorów PaDEL daje $p \gg n \rightarrow$ **gwarantowane przeuczenie**. Wybrano 6 chemicznie umotywowanych deskryptorów typu LSER: $\log D$, $M'w$, $\varepsilon\alpha$, $\varepsilon\beta$, V' , π .

⚠ Podział uczący/testowy wykonano metodą Kennarda–Stone'a.

Metoda Kennarda–Stone'a wybiera związki do zbioru uczącego tak, aby jak najlepiej reprezentowały **całą różnorodność chemiczną** danych, dzięki czemu ocena modelu jest bardziej wiarygodna niż przy losowym podziale.

EDA i wybór pary $\{\log D, \epsilon\beta\}$



Rys. Macierz korelacji oraz zależności $\log D$ – LogKda i $\epsilon\beta$ – LogKda . Dominacja $\log D$ i dwuskupieniowa struktura danych.

log D dominuje

najsilniejszy predyktor
($r = +0,88$)

$\epsilon\alpha$ to predyktor pozorny

korelacja wynika z 2 farmaceutyków; w skupieniu hydrofobowym spada do $-0,15 \rightarrow$ odrzucony

Wybór: $\{\log D, \epsilon\beta\}$

VIF $\approx 1,03$ — niemal ortogonalne;
dwa nieskorelowane mechanizmy

Metodyka — rzetelna walidacja bez przecieku

Podział danych

70:30: uczący $n=24$, testowy $n=11$. Dodatkowo podział systematyczny i 200 powtórzonych podziałów losowych.

Standaryzacja

Parametry skalowania liczone wyłącznie na zbiorze uczącym i przenoszone na testowy — bez przecieku informacji.

Selekcja i strojenie

Dobór deskryptorów i hiperparametrów tylko na danych treningowych (LOO-CV), nigdy na zbiorze walidacyjnym.

Modele

MLR (regresja wieloraka) · k-NN (k strojone) · drzewo decyzyjne CART. Ta sama para $\{\log D, \epsilon\beta\}$.


Porównanie modeli — pojedynczy podział myli

Model	R ² (TS)	Q ² (CV)	Q ² ext	RMSEP
MLR {log D, εβ}	0,956	0,917	0,737	0,398
MLR {+π}	0,958	0,911	0,748	0,389
k-NN (k=1)	0,995	0,933	0,787	0,358
Drzewo decyzyjne	0,974	0,889	0,801	0,346

Na jednym podziale modele wyglądają podobnie — to złudne. Zbiór testowy obejmował tylko LogKda 4,5–6,1 (czysta interpolacja). **R²=0,995 dla k-NN to zapamiętywanie danych (k=1), nie predykcja.**


Które z poniższych stwierdzeń dotyczących algorytmu k-NN jest nieprawidłowe?

- a) Algorytm k-NN jest algorytmem nieparametrycznym, co oznacza, że nie przyjmuje żadnych założeń dotyczących zbioru danych.
- b) Algorytm k-NN może być używany zarówno do rozwiązywania problemów regresyjnych, jak i klasyfikacyjnych.
- c) **Algorytm k-NN jest algorytmem leniwym, co oznacza, że uczy się funkcji dyskryminacyjnej z danych uczących.**
- d) Brak prawidłowej odpowiedzi.



Rys. MLR: wartości obserwowane vs przewidywane (TS — kółka, VS — kwadraty) oraz reszty.

Stabilność na 200 losowych podziałach



Q²ext na 200 podziałach

MLR {log D, εβ}

0,909 ± 0,035

min 0,78 · 0% < 0,5

k-NN (k=3)

0,730 ± 0,147

min 0,10 · szeroki rozrzut


Drzewo decyzyjne

0,797 ± 0,213


min -0,50 · wartości ujemne

MLR jest ~4–6× bardziej stabilny i nigdy nie zawodzi.

Dlaczego modele nieliniowe zawodzą



Rys. Dobór k w k -NN (LOO-CV) — optimum przy $k=1$ (zapamiętywanie).



Ważność cech w drzewie — dominacja $\log D$.

k-NN

Krzywa LOO-CV maleje monotonicznie: $k=1 \rightarrow 0,933$, $k=10 \rightarrow 0,334$. Najlepszy dopiero przy czystym zapamiętywaniu — brak generalizacji.

Wspólna wada

Oba zwracają tylko wartości z zakresu treningowego $\rightarrow$ nie potrafią ekstrapolować dla nowych związków.

Drzewo decyzyjne

Ważność $\log D = 0,969$ vs $\epsilon\beta = 0,031$. Predykcje skokowe, oparte na progach.

Najwyższe $R^2 \neq$ najlepszy model

Wybrany model: $\text{MLR } \{\log D, \varepsilon\beta\}$

Gdyby liczyło się samo R^2 , wygrałby k-NN ($R^2=0,994$) — najmniej rzetelny predyktor.

- ✓ **Najstabilniejsza predykcja** — Najwyższy i największy Q^2_{ext} na 200 podziałach — bez ani jednej porażki.
- ✓ **Najmniejsze przeuczenie** — R^2_{fit} 0,939 vs Q^2_{LOO} 0,913 — minimalna luka. Dla k-NN: 0,994 vs 0,918.
- ✓ **Pełna interpretowalność** — Jawne równanie z mechanistycznie poprawnymi znakami współczynników.
- ✓ **Zdolność do ekstrapolacji** — k-NN i drzewo zwracają tylko wartości treningowe — dyskwalifikujące dla nowych związków.

Luka dopasowanie $\rightarrow$ predykcja (miara przeuczenia)

MLR



R^2_{fit} 0,939 $\rightarrow$ Q^2 0,913 (Δ 0,026)

k-NN



R^2_{fit} 0,994 $\rightarrow$ Q^2 0,918 (Δ 0,076)

Drzewo



R^2_{fit} 0,974 $\rightarrow$ Q^2 0,885 (Δ 0,089)

Im krótszy pasek, tym mniejsze przeuczenie. MLR wygrywa.

Równanie modelu i interpretacja OECD

$$\text{LogKda} = 6,735 + 0,751 \cdot \log D - 19,32 \cdot \epsilon\beta$$

$$R^2 = 0,939 \cdot R^2_{\text{adj}} = 0,935 \\ Q^2_{\text{cv}} = 0,913 \cdot F = 244,2 \cdot n = 35$$

+ log D (lipofilowość)

Współczynnik standaryzowany +1,446


Wzrost hydrofobowości zwiększa adsorpcję na niepolarniej powierzchni PP — oddziaływania hydrofobowe oraz π – π dla związków aromatycznych. To czynnik dominujący (~2,3× silniejszy).

– $\epsilon\beta$ (zasadowość wiązania H)

Współczynnik standaryzowany –0,630

Zdolność do przyjmowania wiązania wodorowego sprzyja pozostawianiu związku w fazie wodnej, co obniża adsorpcję. Oba znaki są mechanistycznie poprawne i zgodne z literaturą.

Domena stosowalności (OECD)



Rys. Wykres Williamsa. Próg dźwigni $h^* = 0,257$; granice ± 3 reszty std.

Cztery zasady OECD — spełnione

- **Zdefiniowany punkt końcowy**
LogKda na PP, jednoznaczny algorytm (MLR)
- **Jakość dopasowania i stabilność**
 R^2 0,939, Q^2_{cv} 0,913, stabilny na 200 podziałach
- **Zdefiniowana domena stosowalności**
wykres Williamsa; sulfadiazyna i trimetoprim
wpływowe
- **Interpretacja mechanistyczna**
hydrofobowość + zasadowość H — fizycznie poprawna

True external validation: naftalen i nitrobenzen

Naftalen

LogKda $\approx$ **3,50**

Wewnątrz domeny ($h = 0,083$; najbliższy: fenantren).

Nitrobenzen

LogKda $\approx$ **1,81**

Predykcja graniczna ($h = 0,153$). Leży w luce log D 1–4,2, brak nitroaromatów w zbiorze.

Modele nieliniowe zawodzą w luce danych:

Związek	MLR (wybrany)	k-NN (k=1)	Drzewo
Naftalen	3,50	4,00	2,38
Nitrobenzen	1,81	0,59	0,72

k-NN i drzewo „przyciągają” nitrobenzen do wartości farmaceutyku (0,59) — błędnie. To uzasadnia wybór modelu liniowego.

Wnioski

- 1 Najlepszy model**

MLR: $\text{LogKda} = 6,735 + 0,751 \cdot \log D - 19,32 \cdot \epsilon\beta$ (R^2 0,939; Q^2_{cv} 0,913). Wybrany za stabilność, brak przeuczenia i interpretowalność — nie za najwyższe R^2 .
- 2 Modele nieliniowe odrzucone**

k-NN i drzewo mają podobne dopasowanie, lecz są niestabilne i niezdolne do ekstrapolacji — dyskwalifikujące dla nowych związków.
- 3 Mechanizm**

Sorpcja zdominowana przez hydrofobowość (sprzyja), z udziałem zasadowości H (przeciwdziała).
- 4 Walidacja zewnętrzna**

Naftalen (3,5) — wiarygodny, wewnątrz domeny. Nitrobenzen (1,8) — graniczny, luka w danych.