

Model QSPR przewidujący współczynnik podziału

mikroplastik–woda morska LogK_{da}

dla polipropylenu (PP) na podstawie deskryptorów molekularnych

Analiza ilościowej zależności struktura–właściwość · regresja wieloraka, k-NN, drzewo decyzyjne

Raport z projektu modelowania chemometrycznego

Zbiór: 35 związków organicznych · 6 deskryptorów typu LSER · cel: EXP LogK_{da}

Streszczenie

Celem pracy było zbudowanie i zwalidowanie modelu QSPR przewidującego logarytm współczynnika podziału mikroplastik–woda morska (LogK_{da}) dla cząstek polipropylenu na podstawie obliczeniowych deskryptorów struktury i właściwości fizykochemicznych. Punktem wyjścia był zbiór 35 związków organicznych (farmaceutyki, izomery heksachlorocykloheksanu, wielopierścieniowe węglowodory aromatyczne oraz chlorobenzeny i polichlorowane bifenyle) z eksperymentalnie wyznaczonymi wartościami LogK_{da} w zakresie 0,59–7,0.

Spośród dostępnych deskryptorów wytypowano — w oparciu o logikę QSPR oraz analizę współliniowości — dwuparametrowy model regresji wielorakiej oparty na lipofilowości (log D) i zasadowości wiązania wodorowego (ϵ_β). Model ten porównano z metodą k najbliższych sąsiadów (k-NN) oraz drzewem decyzyjnym. Wybrany model MLR osiągnął $R^2 = 0,939$ oraz Q^2 walidacji krzyżowej = 0,913, a w teście stabilności na 200 losowych podziałach uzyskał najwyższą i najbardziej powtarzalną zdolność predykcyjną ($Q^2_{\text{ext}} = 0,91 \pm 0,04$, ani razu $< 0,78$), przewyższając modele nieliniowe pod względem rzetelności i interpretowalności.

Model zastosowano do prawdziwej walidacji zewnętrznej, przewidując LogK_{da} dla naftalenu ($\approx 3,5$; wewnątrz domeny stosowalności, predykcja wiarygodna) oraz nitrobenzenu ($\approx 1,8$; predykcja graniczna — związek leży w słabo opróbowanym obszarze przestrzeni deskryptorów). Obie wartości są spójne z danymi literaturowymi dla sorpcji tych związków na mikroplastikach, co potwierdza poprawność mechanistyczną i fizyczną modelu.

Spis treści

1. Wprowadzenie i cel pracy
 2. Dane źródłowe i ich przygotowanie
 3. Analiza eksploracyjna danych (EDA)
 4. Selekcja deskryptorów
 5. Metodyka modelowania
 6. Wyniki i porównanie modeli
 7. Wybór modelu najlepszego
 8. Równanie modelu MLR i interpretacja mechanistyczna
 9. Domena stosowalności modelu
 10. Walidacja zewnętrzna — predykcja dla naftalenu i nitrobenzenu
 11. Porównanie z danymi literaturowymi
 12. Wnioski
 13. Ograniczenia i kierunki dalszych prac
 14. Propozycja wystąpienia (≤ 12 minut)
- Bibliografia

1. Wprowadzenie i cel pracy

Mikroplastiki adsorbują na swojej powierzchni zanieczyszczenia organiczne, działając jako ich nośnik w środowisku morskim. Miara powinowactwa związku do tworzywa jest współczynnik podziału mikroplastik–woda K_d (w jednostkach L/kg), zwyczajowo wyrażany w skali logarytmicznej jako LogK_{da}. Ilościowe modele zależności struktura–właściwość (QSPR) pozwalają przewidywać tę wielkość na podstawie deskryptorów molekularnych, bez konieczności prowadzenia żmudnych pomiarów dla każdego związku z osobna.

Celem pracy było: (1) zbudowanie modelu QSPR dla LogK_{da} na polipropylenie z zachowaniem zasad dobrej praktyki modelowania (wybór deskryptorów oparty na mechanizmie, brak przecieku informacji, rzetelna walidacja); (2) porównanie modelu liniowego (MLR) z modelami nieliniowymi (k-NN, drzewo decyzyjne) i wybór modelu najlepszego pod kątem stabilnej predykcyjności oraz interpretowalności; (3) ocena domeny stosowalności; (4) prawdziwa walidacja zewnętrzna — predykcja dla naftalenu i nitrobenzenu; oraz (5) konfrontacja wyników z literaturą.

2. Dane źródłowe i ich przygotowanie

Dane wejściowe (arkusz „PROJEKT”) liczyły 37 wierszy i 1998 kolumn: nazwę związku, zmienną zależną EXP LogK_{da}, sześć celowo dobranych deskryptorów typu LSER (log D; M'_w = masa molowa/100; ϵ_α — kwasowość wiązania wodorowego; ϵ_β — zasadowość wiązania wodorowego; V' — objętość molekularna; π — polaryzowalność/dipolarność) oraz blisko 1990 automatycznie wygenerowanych deskryptorów typu PaDEL/Dragon.

2.1. Wykluczenie deskryptorów automatycznych

Blok ~1990 deskryptorów PaDEL został świadomie wyłączony z modelowania. Przy zaledwie $n = 35$ obiektach liczba zmiennych wielokrotnie przewyższałaby liczbę obserwacji ($p \gg n$), co prowadzi do przeuczenia i modeli nie do obrony metodologicznie. Deskryptory te nie są też dostępne ani spójne dla związków zewnętrznych. Do modelowania użyto wyłącznie sześciu deskryptorów „projektowych” — chemicznie umotywowanego zestawu LSER, tożsamego z opisanym w pracy źródłowej (Li i wsp., 2020).

2.2. Uszkodzone wiersze związków zewnętrznych — kluczowa uwaga

Dwa ostatnie wiersze pliku (naftalen i nitrobenzen) miały puste wartości zmiennej zależnej oraz uszkodzone/niespójne deskryptory: $\epsilon_\alpha = 0,000$ (wartość zastępcza; wszystkie rzeczywiste związki mają $\epsilon_\alpha \approx 0,23\text{--}0,28$) oraz błędne masy molowe (w pliku naftalen $M'_w = 1,085 \rightarrow 108,5$ g/mol, podczas gdy poprawnie jest 128,2; nitrobenzen 89,1 zamiast 123,1). Z tego powodu wartości z pliku odrzucono, a do predykcji zewnętrznej wykorzystano poprawne, standardowo wyznaczone deskryptory podane przez prowadzącego (np. naftalen $M'_w = 1,281 \checkmark$). Jest to istotny punkt metodyczny: predykcja na podstawie wartości z pliku byłaby obciążona błędem grubym.


2.3. Czyszczenie i kontrola jakości

Ostateczny zbiór modelowy liczył 35 związków z kompletną wartością LogK_{da}. Nie stwierdzono braków danych, zduplikowanych wektorów deskryptorów ani kolumn stałych wśród sześciu zmiennych; z nazw usunięto twarde spacje. Zmienna zależna: zakres 0,59–7,0, średnia 4,82,

odchylenie standardowe 1,54. Dane wykazują strukturę dwuskupieniową — 2 farmaceutyki o niskim LogK_{da} (log D < 1) oraz 33 związki hydrofobowe (log D 4,26–8,27), z pustą luką w zakresie log D ≈ 1–4,2 — dokładnie tam, gdzie wypada nitrobenzen (log D 1,85) i częściowo naftalen (log D 3,30).

3. Analiza eksploracyjna danych (EDA)

Najsilniej z LogK_{da} skorelowana jest lipofilowość log D ($r = +0,878$), następnie π (+0,516), ε_α (−0,501), V' (+0,262), M'_w (+0,247) i ε_β (−0,242). Krytyczna obserwacja dotyczy ε_α : jego pozorna predykcyjność wynika wyłącznie z dźwigni dwóch farmaceutyków — w obrębie samego skupienia hydrofobowego ($n = 33$) korelacja log D z LogK_{da} pozostaje silna (+0,795, zależność rzeczywista), natomiast korelacja ε_α załamuje się do −0,152. Z tego względu ε_α został wykluczony jako predyktor pozorny. Najsilniejsze zależności międzydeskryptorowe to ε_β – π (−0,710) oraz M'_w – V' (+0,655).



Rys. 1. Mapa korelacji sześciu deskryptorów i zmiennej zależnej oraz wykresy rozrzutu log D–LogK_{da} i ε_β –LogK_{da}. Widoczna dominacja log D i dwuskupieniowa struktura danych.

4. Selekcja deskryptorów

Przeprowadzono wyczerpujące przeszukanie wszystkich podzbiorów deskryptorów ($k = 1 \dots 4$), oceniając je metodą walidacji „pomiń-jeden” (LOO-Q²). Najlepszy zestaw dwuparametrowy to {log D, ε_β }: $R^2 = 0,939$, skorygowane $R^2 = 0,935$, $Q^2_{LOO} = 0,913$, przy maksymalnym VIF ≈ 1,03 (log D i ε_β są niemal ortogonalne). Sam log D dawał $R^2 = 0,771$ i $Q^2_{LOO} = 0,720$. Bogatszy wariant {log D, ε_β , π } poprawiał dopasowanie marginalnie ($R^2 = 0,941$), nie zwiększając przy tym istotnie predykcyjności — zgodnie z zasadą parsymonii pozostano przy modelu dwuparametrowym.

Decyzja o wyborze pary {log D, ε_β } została podjęta a priori, na podstawie logiki QSPR i analizy współliniowości, przed jakąkolwiek oceną na zbiorze walidacyjnym — co eliminuje ryzyko przecieku informacji. Uzasadnienie mechanistyczne: log D opisuje hydrofobowy charakter związku (sprzyja adsorpcji na niepolarnym PP), a ε_β — zdolność do bycia akceptorem wiązania wodorowego (sprzyja pozostawianiu w fazie wodnej, zmniejszając adsorpcję). Para ta łączy dwa nieskorelowane, komplementarne mechanizmy.

4.1. Współliniowość (VIF) pełnego zestawu

Dla porównania, czynniki inflacji wariancji w pełnym sześcioparametrowym zestawie wynosiły: log D 2,69; M'_w 7,49; ε_α 1,99; ε_β 5,87; V' 4,53; π 3,43. Wysokie VIF dla M'_w i ε_β w pełnym modelu

(efekt współliniowości z innymi zmiennymi) dodatkowo przemawiają za modelem oszczędnym, w którym wybrana para wykazuje VIF ≈ 1 .

5. Metodyka modelowania

- Podział danych: główny podział losowy 70:30 (ziarno = 42) → zbiór treningowy $n = 24$, zbiór walidacyjny $n = 11$. Dodatkowo zastosowano podział systematyczny (co czwarty obiekt) oraz 200 powtórzonych podziałów losowych w celu oceny stabilności.
- Standaryzacja (obowiązkowa): parametry skalowania (średnia, odchylenie) wyznaczano wyłącznie na zbiorze treningowym i stosowano do zbioru walidacyjnego oraz związków zewnętrznych — bez przecieku informacji.
- Selekcja deskryptorów i strojenie hiperparametrów odbywały się wyłącznie na danych treningowych (walidacja krzyżowa), nigdy na zbiorze walidacyjnym.
- Modele: regresja liniowa wieloraka (MLR), k najbliższych sąsiadów (k -NN, wagi jednorodne) oraz drzewo decyzyjne CART. Hiperparametry strojono metodą LOO-CV na zbiorze treningowym: k -NN → $k = 1$ (monotoniczny spadek Q^2 wraz z k — sygnatura czystego zapamiętywania); drzewo → maks. głębokość 3, min. liczność liścia 2.
- Metryki: R^2 , RMSE i MAE na zbiorze treningowym; Q^2 oraz RMSE walidacji krzyżowej (CV na TS); Q^2_{ext} , RMSEP i MAE_{ext} na zbiorze walidacyjnym, gdzie mianownik Q^2_{ext} liczono względem średniej zbioru treningowego ($\bar{y}_{\text{TS}}$), zgodnie z definicją:

$$Q^2_{\text{ext}} = 1 - \frac{\sum (y_{\text{obs,VS}} - y_{\text{pred,VS}})^2}{\sum (y_{\text{obs,VS}} - \bar{y}_{\text{TS}})^2}$$


6. Wyniki i porównanie modeli

6.1. Tabela porównawcza (podział główny 70:30)

Zestawienie metryk dla podziału głównego (TS = 24, VS = 11). Wszystkie modele korzystają z tej samej pary deskryptorów {log D, $\epsilon\beta$ }.

Model	$R^2(\text{TS})$	RMSE(TS)	MAE(TS)	$Q^2(\text{CV})$	RMSE(CV)	$Q^2(\text{ext})$	RMSEP	MAE(ext)
MLR {log D, $\epsilon\beta$ }	0,956	0,371	0,280	0,917	0,508	0,737	0,398	0,294
MLR {log D, $\epsilon\beta$, π }	0,958	0,364	0,282	0,911	0,529	0,748	0,389	0,287
k -NN ($k = 1$)	0,995	0,127	0,037	0,933	0,458	0,787	0,358	0,280
Drzewo decyzyjne	0,974	0,286	0,233	0,889	0,591	0,801	0,346	0,278

Na pojedynczym podziale modele wyglądają porównywalnie, a k -NN i drzewo mają nawet nieco wyższe Q^2_{ext} . Jest to jednak złudne: zbiór walidacyjny tego podziału obejmował wyłącznie zakres LogK_{da} 4,50–6,06 (sama interpolacja), więc test ten słabo różnicuje modele. Uwaga: bardzo wysokie $R^2(\text{TS}) = 0,995$ dla k -NN to efekt zapamiętywania danych treningowych ($k = 1$), a nie rzeczywistej jakości predykcji.




Rys. 2. Model MLR: wartości obserwowane vs przewidywane (TS — niebieskie kółka, VS — czerwone kwadraty, linia $y = x$) oraz wykres reszt. Dwa farmaceutyki (niski LogK_{da}) widoczne jako punkty o dużym wpływie.

6.2. Test stabilności (200 losowych podziałów 70:30) — decydujący

Aby ocenić rzetelność predykcji niezależnie od jednego losowego podziału, powtórzono procedurę 200 razy przy ustalonym pipeline (k-NN $k = 3$, drzewo gł. 3 / liść 2):

Model	Q ² (ext) śr.	± odch.	mediana	min	% ujemnych
MLR {log D, εβ}	0,909	0,035	0,912	0,783	0 %
k-NN (k = 3)	0,730	0,147	0,758	0,096	0 %
Drzewo decyzyjne	0,797	0,213	0,870	-0,503	1 %


Model MLR jest ~4–6× bardziej stabilny od modeli nieliniowych i nigdy nie zawodzi (Q²_{ext} nie spada poniżej 0,78). k-NN i drzewo wykazują szeroki rozrzut, z wartościami poniżej 0,5, a drzewo nawet ujemne (predykcja gorsza od średniej). Podział systematyczny (co czwarty obiekt, „łatwy”, czysto interpolacyjny) dawał dla wszystkich trzech modeli Q²_{ext} ≈ 0,91 — co dobitnie pokazuje, dlaczego walidacja na pojedynczym podziale potrafi wprowadzać w błąd.



Rys. 3. Rozkład Q^2_{ext} na 200 losowych podziałach. MLR — wąski, wysoko położony przedział; k-NN i drzewo — szerokie rozkłady z wartościami poniżej progu akceptowalności (0,5) i ujemnymi.

6.3. Diagnostyka k-NN i drzewa decyzyjnego

Dla k-NN krzywa LOO-CV jest monotonicznie malejąca ($k = 1 \rightarrow Q^2 = 0,933$; $k = 3 \rightarrow 0,787$; $k = 10 \rightarrow 0,334$), co oznacza, że metoda działa najlepiej przy czystym zapamiętywaniu pojedynczego sąsiada — to typowa oznaka braku zdolności do generalizacji. Drzewo decyzyjne przypisuje niemal cały „udział” lipofilowości: ważność $\log D = 0,969$ wobec $\varepsilon_\beta = 0,031$, co potwierdza dominującą rolę hydrofobowości, ale jednocześnie pokazuje ubóstwo struktury modelu opartego na progach.



Rys. 4. Po lewej: dobór k w k-NN (LOO-CV) — optimum przy $k = 1$ (sygnatura zapamiętywania). Po prawej: ważność cech w drzewie decyzyjnym — dominacja $\log D$.

7. Wybór modelu najlepszego

Jako model najlepszy wybrano MLR $\{\log D, \varepsilon_\beta\}$. Decyzja nie opiera się na najwyższym R^2 dopasowania — gdyby tak było, należałoby wybrać k-NN ($R^2_{fit} = 0,994$), który jest jednak najmniej

rzetelnym predyktorem. Jest to podręcznikowy przykład pozornej jakości wynikającej z przeuczenia.

Argumenty rozstrzygające:

1. Najwyższa i najbardziej stabilna predykcijność zewnętrzna (200 podziałów), bez ani jednej porażki.
2. Najmniejsza różnica między dopasowaniem a predykcją (R^2_{fit} 0,939 vs Q^2_{LOO} 0,913) — najmniejsze przeuczenie. Dla k-NN różnica ta jest duża (0,994 vs 0,918), a drzewo wypada najslabiej w LOO (0,885).
3. Pełna interpretowalność — jawne równanie z mechanistycznie poprawnymi znakami współczynników.
4. Zdolność do liniowej ekstrapolacji. k-NN i drzewo zwracają wyłącznie wartości z zakresu treningowego (najbliższy sąsiad / wartość w liściu) — co jest dyskwalifikujące dla związków zewnętrznych, zwłaszcza nitrobenzenu leżącego w luce danych (sekcja 10).

8. Równanie modelu MLR i interpretacja mechanistyczna

Model wdrożeniowy (dopasowany na wszystkich 35 związkach) ma postać — w zmiennych standaryzowanych:

$$\text{LogK}_{\text{da}} = 4,822 + 1,446 \cdot z(\log D) - 0,630 \cdot z(\epsilon_{\beta})$$

oraz w zmiennych surowych (nieskalowanych):

$$\text{LogK}_{\text{da}} = 6,735 + 0,751 \cdot \log D - 19,32 \cdot \epsilon_{\beta}$$

$R^2 = 0,939$; skorygowane $R^2 = 0,935$; s (RMSE dopasowania) = 0,393; $F(2, 32) = 244,2$ ($p \approx 0$); $n = 35$. Współczynniki (postać standaryzowana):

Parametr	wsp. (std)	SE	t	p	wsp. (surowy)
Wyraz wolny	4,822	0,066	72,6	< 0,0001	6,735
$z(\log D)$	+1,446	0,068	21,40	< 0,0001	+0,751
$z(\epsilon_{\beta})$	-0,630	0,068	-9,33	< 0,0001	-19,32

Interpretacja w duchu wytycznych OECD: oba znaki są mechanistycznie poprawne. Dodatni współczynnik przy $\log D$ oznacza, że wzrost hydrofobowości zwiększa adsorpcję na niepolarnej powierzchni polipropylenu (oddziaływania hydrofobowe i — dla związków aromatycznych — π - π). Ujemny współczynnik przy ϵ_{β} oznacza, że zdolność związku do przyjmowania wiązania wodorowego sprzyja jego pozostawianiu w fazie wodnej i obniża adsorpcję. Lipofilowość jest czynnikiem $\sim 2,3\times$ silniejszym niż zasadowość wiązania wodorowego (porównanie współczynników standaryzowanych), co jest spójne z mechanizmem opisanym w literaturze (oddziaływanie hydrofobowe + π - π + zasadowość H + energia tworzenia wnęki).

9. Domena stosowalności modelu


Domenę oceniono metodą wykresu Williamsa (dźwignia względem reszt standaryzowanych). Próg dźwigni wynosi:

$$h^* = 3(p + 1) / n = 3 \cdot 3 / 35 = 0,257$$

W zbiorze treningowym jedynie sulfadiazyna ma dźwignię powyżej progu ($h = 0,45$), a trimetoprim jest odstający na osi reszt (reszta std. = $-3,09$); oba farmaceutyki są obiektami wpływowymi, co potwierdza wcześniejszą uwagę o strukturze dwuskupieniowej. Dla związków zewnętrznych (model używa log D i ε_β , obu w zakresie treningowym):

Związek	log D	ε_β	dźwignia h	najbliższy zw. wzorcowy (odl. std)	LogK _{da} (MLR)	ocena
Naftalen	3,30	0,296	0,083	fenantren (0,55)	≈ 3,50	wewnątrz domeny
Nitrobenzen	1,85	0,327	0,153	trimetoprim (1,25)	≈ 1,81	graniczna

Naftalen leży pewnie wewnątrz domeny ($h = 0,083$, najbliższy sąsiad — fenantren w odległości 0,55 odchylenia; odległość od centroidu 1,48 przy maksymalnej 4,03) → predykcja wiarygodna. Nitrobenzen formalnie przechodzi kryteria dźwigni i zakresu min–maks ($h = 0,153 < h^*$), lecz wypada w pustej luce log D 1–4,2, a jego najbliższym sąsiadem jest odstający trimetoprim (1,25 odchylenia). W zbiorze treningowym brak nitroaromatów i analogicznych grup funkcyjnych → predykcję należy traktować ostrożnie jako interpolację w słabo opróbowanym, strukturalnie odmiennym obszarze.



Rys. 5. Wykres Williamsa. Linia $h^* = 0,257$ i granice ± 3 reszty std. Sulfadiazyna i trimetoprim oznaczone; związki zewnętrzne (zielone trójkąty) umieszczono na poziomie reszty 0, gdyż ich wartość obserwowana jest nieznaną.

10. Walidacja zewnętrzna — predykcja dla naftalenu i nitrobenzenu

Predykcję wykonano na podstawie poprawnych deskryptorów (sekcja 2.2), korzystając z modelu wdrożeniowego MLR. Otrzymano LogK_{da} ≈ 3,50 dla naftalenu oraz ≈ 1,81 dla nitrobenzenu. Modele nieliniowe — niezdolne do interpolacji w luce — zawodzą: k-NN (k = 1) zwraca 4,00 i 0,59, a drzewo decyzyjne 2,38 i 0,72. Oba modele „przyciągają” nitrobenzen do niskiej wartości farmaceutyku, co jest ewidentnie błędne i potwierdza wybór modelu liniowego do ekstrapolacji.

11. Porównanie z danymi literaturowymi

Zbiór odpowiada pracy Li i wsp. (2020, Scientific Reports), która dla układu PP/woda morska wykorzystuje dokładnie 35 eksperymentalnych wartości K_d, te same klasy związków oraz zestaw $\log D + M'_w$ + sześć deskryptorów kwantowo-chemicznych. Modele w tej pracy osiągają R² 0,811–0,939, Q²_{ext} 0,835–0,910, RMSE_{ext} 0,369–0,752 oraz VIF 1,000–1,204 — uzyskane tu wartości mieszczą się w tych zakresach. Praca podaje logK_d fenantrenu na PP równe 4,00 (zgodność z danymi potwierdza tożsamość zbioru) i wskazuje ten sam mechanizm: oddziaływanie hydrofobowe, π-π, zasadowość wiązania wodorowego i energia tworzenia wnęki — spójny z modelem {log D, ε_β}.

Wartości eksperymentalne dla związków zewnętrznych: dla naftalenu logK_d na różnych mikroplastikach mieści się w przedziale ~2,6–3,5 (np. 3,45; 3,25; 3,01; 2,59 dla różnych polimerów); przewidziane 3,50 leży przy górnej krawędzi, co jest zgodne z łagodną ekstrapolacją domeny (dla dwupierścieniowego naftalenu oczekiwana wartość jest o ~1 jednostkę logarytmiczną niższa od fenantrenu, tj. ~3,0). Dla nitrobenzenu literaturowe logK_d na polistyrenie sięga ~1,6–3,1 (Wang i wsp., 2019); przewidziane 1,81 mieści się w dolnej części tego zakresu, co jest sensowne, gdyż PP zwykle sorbuje związki π nieco słabiej niż PS. Obie predykcje są zatem fizycznie wiarygodne — naftalen dobrze potwierdzony, nitrobenzen rzędu wielkości poprawny, lecz obarczony większą niepewnością.

12. Wnioski

5. Najlepszym modelem jest dwuparametrowa regresja liniowa $\text{LogKda} = 6,735 + 0,751 \cdot \log D - 19,32 \cdot \varepsilon_{\beta}$ (R² = 0,939; Q²_{cv} = 0,913), wybrana ze względu na stabilną predykcyjność, brak przeuczenia i pełną interpretowalność.
6. Modele nieliniowe (k-NN, drzewo) mają wyższe lub porównywalne dopasowanie, lecz są niestabilne i niezdolne do ekstrapolacji — co dyskwalifikuje je w zadaniu predykcji dla nowych związków.
7. Mechanizm sorpcji jest zdominowany przez hydrofobowość (sprzyja adsorpcji), z udziałem zasadowości wiązania wodorowego (przeciwdziała adsorpcji) — zgodnie z literaturą.
8. Naftalen (LogKda ≈ 3,5) leży wewnątrz domeny — predykcja wiarygodna. Nitrobenzen (≈ 1,8) jest predykcją graniczną z uwagi na lukę w danych i brak analogów strukturalnych.
9. Wyniki są w pełni spójne z pracą źródłową Li i wsp. (2020) oraz z eksperymentalnymi wartościami sorpcji obu związków na mikroplastikach.

13. Ograniczenia i kierunki dalszych prac

- Mała liczność zbioru ($n = 35$) i jego dwuskupieniowa struktura ograniczają pewność modelu w luce $\log D \approx 1-4,2$.
- Brak w zbiorze treningowym nitroaromatów i innych grup funkcyjnych zwiększa niepewność predykcji dla nitrobenzenu.
- Model dotyczy wyłącznie polipropylenu i wody morskiej; przeniesienie na inne polimery (PE, PS) lub matryce wymaga osobnej walidacji.
- Rekomendacja: uzupełnienie zbioru o związki z zakresu $\log D$ 1–4 (w tym nitroaromaty i związki polarne) oraz eksperymentalne potwierdzenie predykcji dla nitrobenzenu na PP.

14. Propozycja wystąpienia (≤ 12 minut)

Proponowany podział czasu i treści dwunastominutowej prezentacji:

Czas	Sekcja	Treść / slajd
0:00–1:00	Wprowadzenie i cel	Czym jest LogK _{da} , po co model QSPR, jakie pytanie badawcze.
1:00–2:30	Dane i ich kontrola	35 związków, 6 deskryptorów LSER; wykluczenie ~1990 deskryptorów PaDEL; uszkodzone wiersze związków zewnętrznych (kluczowa uwaga).
2:30–4:00	EDA i selekcja deskryptorów	Dominacja $\log D$; pozornosc $\epsilon\alpha$; wybór pary $\{\log D, \epsilon\beta\}$; VIF ≈ 1 (Rys. 1).
4:00–5:00	Metodyka	Podział, standaryzacja, brak przecieku, walidacja krzyżowa i definicja Q^2_{ext} .
5:00–7:30	Porównanie modeli	Tabela metryk; Rys. 2 (obs vs pred); kluczowy Rys. 3 (stabilność na 200 podziałach); dlaczego k-NN/drzewo zawodzą (Rys. 4).
7:30–8:30	Wybór modelu	Najwyższe $R^2 \neq$ najlepszy model; argument przeuczenia i ekstrapolacji.
8:30–9:30	Równanie i mechanizm	Wzór MLR, znaki współczynników, interpretacja OECD.
9:30–10:30	Domena i predykcja zewnętrzna	Wykres Williamsa (Rys. 5); naftalen $\approx 3,5$ (wiarygodny), nitrobenzen $\approx 1,8$ (ostrożnie).
10:30–11:30	Literatura	Zgodność z Li i wsp. (2020) i wartościami eksperymentalnymi.
11:30–12:00	Wnioski	Trzy zdania podsumowania + rekomendacja.

Wskazówka prezentacyjna: na jednym slajdzie pokazać Rys. 3 (stabilność) jako kulminację — to on uzasadnia całą decyzję o wyborze modelu. Slajdy techniczne ograniczyć do 1–2 liczb każdy.

Bibliografia

- Li Y., Yu Q., Wang W., Li L., Ma Y., Wei J. (2020). QSPR models for predicting the adsorption capacity for microplastics of polyethylene, polypropylene and polystyrene. *Scientific Reports* 10:14597. <https://doi.org/10.1038/s41598-020-71390-3>
- Lee H., Shim W.J., Kwon J.-H. (2014). Sorption capacity of plastic debris for hydrophobic organic chemicals. *Science of the Total Environment* 470–471:1545–1552. <https://doi.org/10.1016/j.scitotenv.2013.08.023>

Wang J., Liu X., Liu G. i wsp. (2019). Sorpcja związków aromatycznych i nitroaromatycznych (w tym naftalenu i nitrobenzenu) na mikro- i mezoplastikach. *Ecotoxicology and Environmental Safety* 173:331–338 / *Environmental Science and Pollution Research* 26:12563–12573.

Hüffer T., Hofmann T. (2016). Sorption of non-polar organic compounds by micro-sized plastic particles in aqueous solution. *Environmental Pollution* 214:194–201.

OECD (2007). Guidance Document on the Validation of (Q)SAR Models. *OECD Series on Testing and Assessment No. 69*, Paris.