

QSPR dla adsorpcji zanieczyszczeń organicznych na polipropylenie

Endpoint: LogKd • modele: MLR, kNN regression, Decision Tree regression

35

związki modelowane

25/10

podział TS/VS

1996

deskryptory w Excelu

MLR

model końcowy

Prezentacja krytyczna: nie tylko wysokie R^2 , ale także walidacja zewnętrzna, stabilność i domena stosowalności.

Cel i kontekst projektu

Model QSPR ma przewidywać LogKd adsorpcji na PP dla związków bez pomiarów eksperymentalnych.

Problem praktyczny

- dane eksperymentalne LogKd są kosztowne i ograniczone
- PP jest hydrofobową powierzchnią sorpcyjną
- związki PBT mogą akumulować się na mikroplastiku

Założenie modelowania

- różnice LogKd wynikają z cech struktury chemicznej
- deskryptory reprezentują hydrofobowość, rozmiar i oddziaływania elektronowe
- model ma przewidywać nowe związki tylko w swojej domenie



LogKd

adsorpcja na PP

Decyzja metodologiczna

- nie użyto pełnej wysokowymiarowej macierzy 1996 deskryptorów wprost
- wybrano mały zestaw mechanistyczny zgodny z true external validation
- VS pozostawiono jako realną walidację zewnętrzną



prediction-ready tylko w AD

Dane i deskryptory

Excel: 37 rekordów; 35 związków z LogKd + 2 związki EXT bez wartości obserwowanej.

25

TS

10

VS

2


EXT

Diagnostyka macierzy

- 1996 kolumn deskryptorów
- 499 kolumn stałych
- 199 prawie stałych
- 56 kolumn z brakami

Wybrany zestaw kandydacki

- log D - hydrofobowość
- Mw' i V' - rozmiar/objętość
- $\epsilon\alpha$, $\epsilon\beta$ - oddziaływania elektronowe
- π - właściwość polaryzacyjna/aromatyczna



1996 → 6 → 3

redukcja wymiarowości bez leakage

Uzasadnienie

- mniej ryzyka przeuczenia przy n=35
- pełna kompatybilność z true external validation
- łatwiejsza interpretacja OECD

Workflow modelowania


Transformacje i selekcję dopasowano wyłącznie na TS, aby nie zanieczyścić walidacji.

Kluczowy rygor

- brak optymalizacji podziału po fakcie
- VS nie bierze udziału w selekcji cech
- CV służy do strojenia, a nie do raportowania triumfu

Metryki raportowane


- TS: R^2 , RMSEC, MAE
- CV: Q^2 CV, RMSECV
- VS: Q^2 Ext/ R^2 , RMSEP, MAE
- AD: leverage + zakres + dystans



Wniosek z workflow: wysoka jakość VS jest ważna, ale nie wystarcza bez AD i interpretowalności.

Porównanie modeli MLR / kNN / Decision Tree

Najwyższy R^2 treningowy nie jest kryterium wyboru modelu.



Model	R^2_{TS}	Q^2_{CV}	Q^2_{Ext}	RMSEP
MLR	0.924	0.871	0.969	0.270
kNN	1.000	0.791	0.970	0.266
Decision Tree	0.989	0.795	0.947	0.356

Krytyczna obserwacja

- kNN ma RMSEC = 0.000 i $R^2_{TS} = 1.000$
- najlepsze VS nie kompensuje ryzyka modelu pamięciowego
- MLR ma niemal ten sam RMSEP i jawne równanie

Decyzja: MLR jako model końcowy

Najlepszy model: MLR

Wybrany model łączy predykcyjność z interpretowalnością i kontrolą współliniowości.

$$\text{LogKd} = 4.881 + 1.463 \cdot z(\log D) - 0.399 \cdot z(\epsilon\beta) + 0.172 \cdot z(\pi)$$

0.871

Q²CV

0.538

RMSECV

0.969

Q²Ext

0.270

RMSEP

0.187

MAE VS




Descriptor	b_std	VIF
log D	1.463	1.59
$\epsilon\beta$	-0.399	2.61
π	0.172	2.33

Mechanistyczny sens

- logD dodatni: hydrofobowość zwiększa sorpcję do PP
- π dodatni: oddziaływania dyspersyjne/aromatyczne
- $\epsilon\beta$ ujemny: bardziej polarny/akceptorowy charakter słabiej wspiera hydrofobową sorpcję

Observed vs predicted i reszty

Model końcowy nie pokazuje typowego rozdziwienku TS vs VS, ale trzeba pilnować AD.



Interpretacja


- TS dobrze opisany bez idealnego dopasowania
- VS leży blisko przekątnej
- reszty bez silnego trendu systematycznego

Ryzyko

- część VS jest strukturalnie bardzo podobna do TS
- wysokie Q^2_{Ext} nie gwarantuje pracy dla związków polarnych
- dlatego true external i AD są krytyczne

Interpretacja OECD i domena stosowalności

Model spełnia podstawowe punkty OECD, ale zakres chemiczny jest wąski.



OECD checklist

- endpoint: LogKd adsorpcji na PP
- algorytm: jawna regresja MLR
- AD: leverage + zakres + dystans
- statystyki: R^2 , Q^2_{CV} , RMSECV, Q^2_{Ext} , RMSEP, MAE
- interpretacja: hydrofobowość i oddziaływania elektronowe

Sygnaly ostrzegawcze

- 3 izomery HCH w VS są poza zakresem wybranych descriptorów
- nitrobenzen jest poza/w strefie ostrzeżenia
- model nie powinien być używany jako uniwersalny QSAR dla całej chemii organicznej

True external validation: nitrobenzene i naphthalene

Predykcja wykonana tylko dlatego, że najlepszy model używa dostępnych deskryptorów.

Związek	Pred. LogKd	AD	Ocena
Naphthalene	3.411	inside	wiarygodna w ramach AD
Nitrobenzene	1.725	outside/warning	ekstrapolacja / ostrożnie

Naphthalene
AD: inside

Co to znaczy?

- naftalen jest w pobliżu przestrzeni TS
- nitrobenzen jest znacznie bardziej polarny i poza zakresem/odległością AD
- dla nitrobenzenu potrzebne byłyby dodatkowe dane albo model obejmujący związki nitroaromatyczne

Nitrobenzene
AD: warning

Ograniczenia, wnioski i pytania do obrony

Najważniejszy przekaz: model jest użyteczny, ale nie poza swoją chemią.

Wnioski końcowe

- MLR wybrano mimo minimalnie lepszego RMSEP kNN
- brak silnych oznak przeuczenia dla MLR
- największe ograniczenie: mały i chemicznie wąski zbiór
- nitrobenzen wymaga ostrożności poza AD

Potencjalne pytania

- Dlaczego nie kNN z najlepszym RMSEP?
- Czy model jest przeuczony?
- Czy deskryptory mają sens fizykochemiczny?
- Czy nitrobenzen i naftalen mieszczą się w AD?
- Co rozszerzyłoby model?

Najkrótsza odpowiedź obronna

MLR jest świadomym kompromisem: trochę mniej efektowny niż kNN, ale stabilny, jawny, interpretowalny i zgodny z zasadami OECD.