

Projekt QSPR: modelowanie adsorpcji zanieczyszczeń organicznych na powierzchni polipropylenu (PP)

Endpoint: LogKd / EXP LogKda

Opracowanie obliczeniowe: diagnostyka danych, MLR, kNN, Decision Tree, walidacja OECD i true external validation

Plan działania: (1) odczyt i diagnostyka danych z Excela, (2) wybór deskryptorów bez data leakage, (3) walidacja TS/VS, (4) porównanie trzech metod ML, (5) wybór najlepszego modelu, (6) ocena domeny stosowalności, (7) predykcje dla naftalenu i nitrobenzenu.

Wszystkie wartości liczbowe w raporcie pochodzą z obliczeń wykonanych na pliku Excel lub z dostarczonych wartości deskryptorów dla true external validation.

1. Diagnostyka danych

Rozpoznano kolumnę odpowiedzi: EXP LogKda. Kolumna 'Set' zawiera gotowy podział TS/VS/EXT. Do modelowania użyto 35 związków z eksperymentalnym LogKd: 25 w TS i 10 w VS. Dwa rekordy EXT to naftalen i nitrobenzen bez wartości obserwowanej LogKd.

Macierz zawiera 1996 kolumn deskryptorów; wszystkie są numeryczne w części modelowanej. Wykryto 56 kolumn z brakami danych, 499 kolumn stałych i 199 prawie stałych. Nie wykryto duplikatów nazw związków w zbiorze modelowanym.

Wartości odstające wg IQR dla odpowiedzi LogKd znajdują się głównie w dolnym zakresie sorpcji: Trimethoprim, Sulfadiazine, β -Hexachlorocyclohexane, δ -Hexachlorocyclohexane, γ -Hexachlorocyclohexane, α -Hexachlorocyclohexane. Nie usuwano ich, ponieważ reprezentują chemicznie istotny, słabiej sorbuujący fragment przestrzeni danych.

Tabela 1. Skrócona diagnostyka danych.

Element	Wynik
Związki modelowane	35
TS / VS / EXT	25 / 10 / 2
Deskryptory całkowite	1996
Kolumny z brakami	56
Kolumny stałe	499
Kolumny prawie stałe	199
Duplikaty nazw	{}

2. Przygotowanie danych

Nie imputowano braków w pełnej macierzy 1996 deskryptorów, ponieważ modelowanie przeprowadzono na małym, mechanistycznie uzasadnionym zestawie sześciu deskryptorów dostępnych dla związków true external validation: log D, Mw', $\epsilon\alpha$, $\epsilon\beta$, V' oraz π . W tych kolumnach nie było braków dla TS/VS.

Standaryzację dopasowywano wyłącznie na TS i stosowano później do VS oraz do naftalenu/nitrobenzenu. Selekcja podzbioru MLR była wykonywana wyłącznie na TS przez 5-krotną walidację krzyżową i ograniczenie VIF < 20. VS nie był używany do kalibracji ani strojenia parametrów.

Tabela 2. Korelacje kandydackich deskryptorów w TS.

Descriptor	log D	Mw'	$\epsilon\alpha$	$\epsilon\beta$	V'	π
log D	1.00	0.49	-0.51	0.36	0.22	0.15
Mw'	0.49	1.00	0.23	0.60	0.69	-0.40
$\epsilon\alpha$	-0.51	0.23	1.00	0.29	0.22	-0.65
$\epsilon\beta$	0.36	0.60	0.29	1.00	-0.04	-0.64
V'	0.22	0.69	0.22	-0.04	1.00	-0.10
π	0.15	-0.40	-0.65	-0.64	-0.10	1.00

3. Modele QSPR


Zbudowano trzy modele: MLR, kNN regression oraz Decision Tree regression. MLR zakłada liniową zależność LogKd od deskryptorów i daje jawne równanie. kNN przewiduje odpowiedź na podstawie najbliższych sąsiadów w przestrzeni standaryzowanych deskryptorów. Drzewo decyzyjne dzieli przestrzeń deskryptorów na regiony o zbliżonych wartościach LogKd.

Parametry kNN i drzewa decyzyjnego dobierano 5-krotną walidacją krzyżową na TS. MLR wybrano przez przegląd podzbiorów 1-4 deskryptorów, z kontrolą współliniowości.

Tabela 3. Porównanie jakości modeli.

Model	Descriptors	n_features	R2_TS	RMSEC	Q2CV	RMSECV	Q2Ext_R2_VS	RMSEP	MAE_VS	Overfit_gap_R2_TS_minus_Q2Ext	CV_selected_params
MLR	log D, $\epsilon\beta$, π	3	0.924	0.413	0.871	0.538	0.969	0.270	0.187	-0.045	"subset by 5-fold CV + VIF<20"
kNN	log D, Mw', $\epsilon\alpha$, $\epsilon\beta$, V', π	6	1.000	0.000	0.791	0.685	0.970	0.266	0.208	0.030	{"knn__n_neighbors": 1, "knn__p": 1, "knn__weights": "uniform"}
Decision Tree	log D, Mw', $\epsilon\alpha$, $\epsilon\beta$, V', π	6	0.989	0.159	0.795	0.679	0.947	0.356	0.300	0.042	{"dt__max_depth": 4, "dt__min_samples_leaf": 1, "dt__min_samples_split": 2}

4. Porównanie modeli



MLR: $R^2_{TS}=0.924$, $Q^2_{CV}=0.871$, $Q^2_{Ext}/R^2_{VS}=0.969$, RMSEP=0.270.

kNN: $R^2_{TS}=1.000$, $Q^2_{CV}=0.791$, $Q^2_{Ext}/R^2_{VS}=0.970$, RMSEP=0.266.

Decision Tree: $R^2_{TS}=0.989$, $Q^2_{CV}=0.795$, $Q^2_{Ext}/R^2_{VS}=0.947$, RMSEP=0.356.

5. Wybór najlepszego modelu

Najlepszym modelem końcowym wybrano MLR. kNN miał minimalnie niższy RMSEP (0.266) niż MLR (0.270), ale kNN w ustawieniu $k=1$ ma $R^2_{TS}=1.000$ i RMSEC=0.000, czyli zachowuje się jak model pamięciowy. MLR daje niemal taką samą predykcyjność zewnętrzną, lepszą interpretowalność i mniejsze ryzyko niekontrolowanego dopasowania do pojedynczych obiektów.

Wybrane równanie MLR dotyczy deskryptorów standaryzowanych w procesie kalibracji:

$$\text{LogKd} = 4.8811 + 1.4635 \cdot z(\log D) - 0.3987 \cdot z(\epsilon\beta) + 0.1721 \cdot z(\pi)$$

Równanie równoważne dla deskryptorów niestandaryzowanych z tej samej skali danych:

$$\text{LogKd} = 4.1061 + 0.6986 \cdot \log D - 13.2998 \cdot \epsilon\beta + 0.7542 \cdot \pi$$

Tabela 4. Współczynniki MLR i VIF.

Descriptor	b_std	b_raw	VIF
log D	1.463	0.699	1.586
$\epsilon\beta$	-0.399	-13.300	2.612
π	0.172	0.754	2.330

6. Walidacja OECD i dziedzina stosowalności

Endpoint jest dobrze zdefiniowany: LogKd adsorpcji zanieczyszczeń organicznych na PP. Algorytm jest przejrzysty, ponieważ MLR ma jawne równanie. Jakość modelu opisują R^2_{TS} , Q^2_{CV} , $RMSECV$, Q^2_{Ext}/R^2_{VS} , $RMSEP$ i MAE . Interpretacja mechanistyczna jest możliwa: dodatni wpływ logD odpowiada zwiększonej hydrofobowości i silniejszej sorpcji do hydrofobowego PP; dodatni wpływ π może odzwierciedlać oddziaływania dyspersyjne/aromatyczne; ujemny współczynnik $\epsilon\beta$ sugeruje, że większa skłonność do oddziaływań typu akceptorowego w tym zbiorze nie sprzyja prostemu mechanizmowi hydrofobowej sorpcji.

Dziedzinę stosowalności oceniono przez leverage/Williams plot dla MLR oraz kontrolę zakresu deskryptorów. Próg leverage $h^* = 0.480$. Dodatkowo sprawdzono odległość do najbliższego obiektu TS w standaryzowanej przestrzeni wybranych deskryptorów; próg 95 percentyla wyniósł 1.385.




Tabela 5. Ocena domeny stosowalności dla VS i true external.

Compound	Set	Predicted_Log Kd	Nearest_distance_std	Distance_AD	Range_AD	Leverage	Leverage_AD	Overall_AD
β -Hexachlorocyclohexane	VS	2.818	0.175	inside	outside	0.408	inside	outside/warning
δ -Hexachlorocyclohexane	VS	2.706	0.351	inside	outside	0.412	inside	outside/warning
α -Hexachlorocyclohexane	VS	2.721	0.301	inside	outside	0.421	inside	outside/warning
2,2',3,5'-tetrachlorobiphenyl	VS	5.209	0.602	inside	inside	0.062	inside	inside
2,3',4,4'-tetrachlorobiphenyl	VS	5.184	0.306	inside	inside	0.080	inside	inside
2,2',4,5,5'-pentachlorobiphenyl	VS	5.652	0.409	inside	inside	0.069	inside	inside

henyl								
2,3',4,4',5-pentachlorobiphenyl	VS	5.662	0.345	inside	inside	0.070	inside	inside
2,3,3',4,4'-pentachlorobiphenyl	VS	5.594	0.244	inside	inside	0.096	inside	inside
2,3,3',4,5,6-hexachlorobiphenyl	VS	6.023	0.267	inside	inside	0.090	inside	inside
2,2',3,3',4,6'-hexachlorobiphenyl	VS	6.010	0.222	inside	inside	0.088	inside	inside
Naphthalene	TRUE_EXT	3.411	1.207	inside	inside	0.123	inside	inside
Nitrobenzene	TRUE_EXT	1.725	1.763	outside	outside	0.318	inside	outside/warning

7. True external validation

Predykcje dla naftalenu i nitrobenzenu wykonano tylko dlatego, że najlepszy model MLR używa deskryptorów dostępnych w dostarczonej tabeli true external validation: logD, $\varepsilon\beta$ i π . Nie wymyślano brakujących deskryptorów.

Tabela 6. Predykcje true external validation.

Compound	Descriptors used	Missing features	Predicted LogKd
Naphthalene	log D, $\varepsilon\beta$, π		3.411
Nitrobenzene	log D, $\varepsilon\beta$, π		1.725



Naphthalene: predykcja LogKd = 3.411 i ocena AD = inside. Nitrobenzene: predykcja LogKd = 1.725, ale AD = outside/warning, więc wynik należy traktować jako ekstrapolację o podwyższonej niepewności.


8. Predykcje najlepszego modelu

Tabela 7. Predykcje MLR dla TS, VS i true external.

Set	Compound	Observed LogKd	Predicted LogKd	Residual_obs_minus_pred
TS	Trimethoprim	0.594	1.624	-1.030
TS	Sulfadiazine	0.853	0.307	0.546
TS	γ -Hexachlorocyclohexane	2.580	2.851	-0.271
TS	Phenanthrene	4.000	4.380	-0.380
TS	Anthracene	4.290	4.693	-0.403
TS	Pentachlorobenzene	4.500	4.104	0.396
TS	Fluoranthene	4.790	4.785	0.005
TS	Pyrene	4.800	5.193	-0.393
TS	2,3-dichlorobiphenyl	4.980	4.344	0.636
TS	2,4'-dichlorobiphenyl	4.980	4.481	0.499
TS	Hexachlorobenzene	5.010	4.533	0.477
TS	2,4,4'-trichlorobiphenyl	5.090	4.803	0.287
TS	2,2',5,5'-tetrachlorobiphenyl	5.090	5.057	0.033
TS	2,2',3,5',6-pentachlorobiphenyl	5.260	5.490	-0.230
TS	2,2',3,3',4,4'-hexachlorobiphenyl	5.450	5.872	-0.422
TS	2,2',3,4',5-pentachlorobiphenyl	5.510	5.506	0.004
TS	Chrysene	5.510	5.398	0.112
TS	3,3',4,4'-tetrachlorobiphenyl	5.630	5.440	0.190
TS	2,3,3',4',6-pentachlorobiphenyl	5.630	5.513	0.117
TS	2,2',3,4',5,5',6-heptachlorobiphenyl	5.730	6.401	-0.671
TS	2,2',3,4,4',5-hexachlorobiphenyl	5.770	6.069	-0.299
TS	Benzo[a]pyrene	6.100	6.221	-0.121
TS	2,2',4,4',5,5'-hexachlorobiphenyl	6.190	5.986	0.204
TS	Benzo[g,h,i]perylene	6.690	6.562	0.128
TS	Dibenz[a,h]anthracene	7.000	6.416	0.584
VS	β -Hexachlorocyclohexane	2.180	2.818	-0.638
VS	δ -Hexachlorocyclohexane	2.230	2.706	-0.476
VS	α -Hexachlorocyclohexane	2.690	2.721	-0.031
VS	2,2',3,5'-tetrachlorobiphenyl	5.140	5.209	-0.069
VS	2,3',4,4'-tetrachlorobiphenyl	5.260	5.184	0.076
VS	2,2',4,5,5'-pentachlorobiphenyl	5.510	5.652	-0.142
VS	2,3',4,4',5-pentachlorobiphenyl	5.710	5.662	0.048
VS	2,3,3',4,4'-pentachlorobiphenyl	5.770	5.594	0.176

VS	2,3,3',4,5,6-hexachlorobiphenyl	6.060	6.023	0.037
VS	2,2',3,3',4,6'-hexachlorobiphenyl	6.190	6.010	0.180
TRUE_EXT	Naphthalene		3.411	
TRUE_EXT	Nitrobenzene		1.725	





9. Wnioski

MLR jest najlepszym wyborem praktycznym: osiąga bardzo dobre wyniki VS, ma stabilną walidację krzyżową i jawne równanie.

kNN uzyskał minimalnie niższy RMSEP, ale konfiguracja $k=1$ oraz $R^2_{TS}=1.000$ wskazują na pamięciowy charakter modelu i większe ryzyko przeuczenia.

Decision Tree jest dopasowane silniej do TS niż MLR, ale ma gorszy RMSEP i większą utratę predykcyjności.

Największym ograniczeniem projektu jest mała liczba związków i silna strukturalna zależność zbioru: część VS to bardzo podobne izomery, więc wysoka Q^2_{Ext} nie gwarantuje uniwersalności modelu dla chemicznie odległych związków.

Nitrobenzen znajduje się poza domeną stosowalności najlepszego modelu, więc jego predykcja nie powinna być używana bez dodatkowych danych eksperymentalnych lub rozszerzenia zbioru treningowego.

10. Gotowy konspekt prezentacji na 12 minut

1. Tytuł: QSPR adsorpcji na PP; endpoint LogKd; autorzy.

2. Cel i kontekst: Dlaczego LogKd dla PP jest ważny środowiskowo; ograniczenia eksperymentów.

3. Dane i deskryptory: 35 związków z LogKd, 25 TS/10 VS, 1996 deskryptorów, wybór 6 kandydatów mechanistycznych.

4. Workflow: Diagnostyka -> standaryzacja TS-only -> CV -> VS -> domena -> true external.

- 5. Porównanie modeli:** Tabela MLR/kNN/DT z R^2 , Q^2_{CV} , $RMSECV$, Q^2_{Ext} , $RMSEP$; wskazanie ryzyka kNN $k=1$.
- 6. Najlepszy model:** MLR, równanie, współczynniki, VIF, interpretacja $\log D/\epsilon\beta/\pi$.
- 7. Wykresy jakości:** Observed vs predicted TS/VS, reszty; brak silnego przeuczenia dla MLR.
- 8. OECD i domena:** Endpoint, algorytm, statystyki, AD; Williams plot; związki VS poza zakresem.
- 9. True external:** Naphthalene 3.411 inside AD; Nitrobenzene 1.725 outside/warning.
- 10. Ograniczenia i wnioski:** Mały zbiór, strukturalne podobieństwo, brak gwarancji dla odległych związków; odpowiedzi na pytania.

11. Potencjalne pytania prowadzącej i odpowiedzi

P: Dlaczego wybrano MLR, a nie model z najwyższym R^2 ? O: Bo kNN ma $R^2_{TS}=1.000$ i $k=1$, czyli odtwarza dane treningowe. MLR ma prawie identyczny $RMSEP$, lepszą interpretowalność i mniejsze ryzyko przeuczenia.

P: Czy model jest przeuczony? O: MLR nie wykazuje klasycznego przeuczenia: $Q^2_{CV}=0.871$, $Q^2_{Ext}=0.969$, a $RMSEP=0.270$. Trzeba jednak pamiętać, że VS zawiera związki podobne strukturalnie do TS.

P: Czy nitrobenzen i naftalen mieszczą się w domenę stosowalności? O: Naftalen mieści się w domenę. Nitrobenzen jest poza/w strefie ostrzeżenia, więc jego predykcja jest mniej wiarygodna.

P: Czy deskryptory mają sens fizykochemiczny? O: Tak. $\log D$ opisuje hydrofobowość, π i $\epsilon\beta$ odnoszą się do oddziaływań elektronowych/polaryzacyjnych. Adsorpcja do PP jest w dużym stopniu związana z hydrofobowością i oddziaływaniami dyspersyjnymi.

P: Jakie jest największe ograniczenie modelu? O: Mały zbiór, dominacja związków chlorowanych/aromatycznych i ograniczona reprezentacja związków polarnych. Dlatego AD jest krytyczna.

Materiały wejściowe: instrukcje projektu QSAR/QSPR, wytyczne do prezentacji końcowej, plik True external validation oraz data_qsar_pls_extended.xlsx.