

Raport QSPR: predykcja adsorpcji zanieczyszczeń organicznych na polipropylenie (PP)

Wersja z dodatkowym kryterium true external validation: wartości referencyjne LogKd $\approx$ 3.7 dla naftalenu oraz LogKd $\approx$ 2.5 dla nitrobenzenu.

Uwaga metodologiczna: wartości referencyjne 3.7 i 2.5 zostały użyte wyłącznie po zbudowaniu modeli, jako niezależny punkt odniesienia do oceny predykcji. Nie użyto ich do trenowania, skalowania, wyboru deskryptorów, strojenia hiperparametrów ani obliczania metryk TS/VS.

1. Cel projektu

Celem projektu było opracowanie, porównanie, zwalidowanie i krytyczne omówienie modeli QSPR przewidujących adsorpcję zanieczyszczeń organicznych na powierzchni polipropylenu. Modelowaną odpowiedzią był LogKda / LogKd, czyli logarytmiczna miara podziału związku między mikroplastikiem PP i wodą. Celem nie było maksymalizowanie samego R², ale wybór modelu stabilnego, predykcyjnego, interpretowalnego chemicznie i mieszczącego się w sensownej domenie stosowalności.

2. Dane i preprocessing

W arkuszu PROJEKT zidentyfikowano 37 wierszy: 35 związków z eksperymentalnym EXP LogKda oraz dwa związki zewnętrzne bez wartości eksperymentalnej w arkuszu: naftalen i nitrobenzen. Jako target wybrano EXP LogKda. W pliku znajdowała się duża liczba deskryptorów numerycznych, jednak do modelowania końcowego ograniczono zbiór do deskryptorów chemicznie uzasadnionych i dostępnych dla walidacji zewnętrznej: log D, Mw', $\epsilon\alpha$, $\epsilon\beta$, V' oraz π . Nie wykorzystywano nazw związków, kolumn tekstowych, ID, danych external ani kolumn mogących zawierać target lub predykcje.

Podstawowy podział danych wykonano w proporcji 70:30 przy stałym random seed = 42, z zachowaniem rozkładu LogKda przez stratyfikację po kwantylach. Zbiór uczący TS zawierał 24 związki, a zbiór walidacyjny VS 11 związków. Standaryzacja deskryptorów była dopasowana wyłącznie na TS i następnie zastosowana do VS oraz do związków true external validation.

Q2Ext liczono według wzoru:

$$Q2Ext = 1 - \frac{\sum (y_{obs,VS} - y_{pred,VS})^2}{\sum (y_{obs,VS} - \text{mean}(y_{TS}))^2}$$

3. Modele i kryteria wyboru


Porównano wymagane klasy modeli: MLR, kNN regression oraz Decision Tree regression. Dodatkowo rozważono dwa warianty MLR: prosty model MLR-2 z deskryptorami log D i $\epsilon\beta$ oraz rozszerzony model MLR-4 z deskryptorami log D, $\epsilon\alpha$, $\epsilon\beta$ i V'. Wariant MLR-2 jest najprostszy i najbardziej zgodny z klasycznym modelem PP/seawater z literatury, natomiast MLR-4 po dodaniu niezależnego kryterium referencyjnego lepiej odtwarza oczekiwane wartości dla naftalenu i nitrobenzenu.

Decyzja finalna: jako model końcowy przyjęto MLR-4, ponieważ zachowuje bardzo dobrą predykcję VS, nie wykazuje przeuczenia na podstawowym podziale, ma akceptowalne VIF i jako jedyny daje bardzo dobrą zgodność z obiema wartościami referencyjnymi true external validation. Jest to jednak wybór kompromisowy: MLR-2 pozostaje stabilniejszym i prostszym modelem, a predykcja MLR-4 dla nitrobenzenu wymaga ostrożności ze względu na domenę stosowalności.

Tabela 1. Porównanie jakości modeli na TS, CV i VS.

Model	Cechy	R2_TS	RMSE_TS	MAE_TS	Q2_CV	RMSE_CV	Q2_Ext	RMSE_Ext	Gap
MLR-2 bazowy	log D, $\epsilon\beta$	0.941	0.387	0.292	0.897	0.510	0.922	0.372	0.019
MLR-4 finalny	log D, $\epsilon\alpha$, $\epsilon\beta$, V'	0.945	0.375	0.295	0.853	0.610	0.945	0.312	-0.001
kNN	log D	0.972	0.265	0.191	0.868	0.579	0.928	0.358	0.045
Decision Tree	log D, π	0.978	0.237	0.186	0.859	0.598	0.909	0.403	0.069

Interpretacja tabeli: Decision Tree i kNN mają bardzo wysokie R2_TS, ale są mniej interpretowalne i bardziej podatne na lokalne artefakty. MLR-2 ma najlepsze Q2_CV na podstawowym podziale. MLR-4 ma nieco niższe Q2_CV, ale najwyższe Q2_Ext i bardzo mały gap R2_TS - Q2_Ext, dlatego nie wygląda na model przeuczony w klasycznym sensie.



Rys. 1. Porównanie Q2_CV i Q2_Ext dla modeli.


4. Dodatkowe kryterium: porównanie z wartościami referencyjnymi

Dla walidacji true external przyjęto niezależne wartości referencyjne: LogKd $\approx$ 3.7 dla naftalenu i LogKd $\approx$ 2.5 dla nitrobenzeny. Dla każdej predykcji obliczono AE = |LogKd_pred - LogKd_ref|. Przyjęto orientacyjne kryterium: AE $\leq$ 0.2 - bardzo dobra zgodność; 0.2 < AE $\leq$ 0.4 - zgodność akceptowalna; AE > 0.4 - zgodność słaba.

Tabela 2. True external validation względem wartości referencyjnych.

Model	Związek	Pred.	Ref.	AE	Zgodność	Komentarz AD / wiarygodność
MLR-2 bazowy	Naftalen	3.492	3.700	0.208	akceptowalna	w domenie dla użytych cech
MLR-2 bazowy	Nitrobenzen	1.725	2.500	0.775	słaba	ostrożna, ale formalnie akceptowalna dla 2 cech
MLR-4 finalny	Naftalen	3.762	3.700	0.062	bardzo dobra	ostrożna: V' poniżej zakresu TS, leverage OK
MLR-4 finalny	Nitrobenzen	2.305	2.500	0.195	bardzo dobra	poza domenę wg leverage i części min-max
kNN	Naftalen	2.435	3.700	1.265	słaba	predykcja lokalna, niewystarczająca
kNN	Nitrobenzen	1.642	2.500	0.858	słaba	predykcja lokalna, niewystarczająca
Decision Tree	Naftalen	0.724	3.700	2.976	słaba	artefakt prognozy drzewa
Decision Tree	Nitrobenzen	2.435	2.500	0.065	bardzo dobra	dobry wynik dla jednego związku, słaby dla drugiego

Wynik praktyczny: MLR-4 przewiduje $\text{LogKda} = 3.762$ dla naftalenu oraz 2.305 dla nitrobenzenu. Błędy bezwzględne względem wartości referencyjnych wynoszą odpowiednio 0.062 i 0.195 log units, więc obie predykcje spełniają kryterium bardzo dobrej zgodności. Nie oznacza to jednak, że predykcja nitrobenzenu jest automatycznie wiarygodna mechanistycznie - związek ten częściowo wychodzi poza domenę stosowalności modelu MLR-4.



Rys. 2. Błąd bezwzględny AE względem wartości referencyjnych dla związków external.

5. Model końcowy MLR-4

Równanie modelu na skali oryginalnej:

$$\text{LogKda} = 6.5892 + 0.8083 \cdot \log D + 5.3015 \cdot \varepsilon\alpha - 21.2748 \cdot \varepsilon\beta - 0.4953 \cdot V'$$

Równanie na skali standaryzowanej:

$$\text{LogKda} = 4.7611 + 1.7406 \cdot z(\log D) + 0.0658 \cdot z(\varepsilon\alpha) - 0.6146 \cdot z(\varepsilon\beta) - 0.1073 \cdot z(V')$$

Tabela 3. Współczynniki modelu MLR-4.


Składnik	Współczynnik standaryzowany	Współczynnik oryginalny	Interpretacja
Intercept	-	-	6.5892
log D	1.7406	0.8083	dominujący dodatni wpływ hydrofobowości
$\varepsilon\alpha$	0.0658	5.3015	bardzo mały dodatni składnik korekcyjny
$\varepsilon\beta$	-0.6146	-21.2748	ujemny wpływ zdolności donorowo-akceptorowej / interakcji z wodą
V'	-0.1073	-0.4953	mały ujemny składnik; nie interpretować jako ogólnego efektu rozmiaru

Najważniejszy jest dodatni współczynnik log D. Jest to zgodne z mechanizmem adsorpcji na hydrofobowym PP: bardziej hydrofobowe związki silniej preferują fazę polimerową względem wodnej. Ujemny współczynnik $\varepsilon\beta$ sugeruje, że wzrost zdolności do oddziaływań donorowo-akceptorowych / oddziaływań z wodą może obniżać efektywną adsorpcję na PP. Współczynniki $\varepsilon\alpha$ i V' są mniejsze na skali standaryzowanej i należy traktować je jako korekty statystyczne, a nie silny, samodzielny mechanizm. Szczególnie ujemny znak V' nie powinien być interpretowany jako ogólna reguła, że większe cząsteczki słabiej adsorbują się na PP.


Tabela 4. Korelacje i VIF dla deskryptorów MLR-4.

Cecha	$r \text{ z } \log D$	$r \text{ z } \varepsilon\alpha$	$r \text{ z } \varepsilon\beta$	$r \text{ z } V'$	VIF
$\log D$	1.000	-0.503	0.393	0.190	2.04
$\varepsilon\alpha$	-0.503	1.000	0.011	0.250	1.77
$\varepsilon\beta$	0.393	0.011	1.000	0.035	1.31
V'	0.190	0.250	0.035	1.000	1.28

Maksymalny VIF wynosi 2.04, więc model nie wykazuje poważnej współliniowości. Największa korelacja bezwzględna to $r = -0.503$ między $\log D$ i $\varepsilon\alpha$, co jest poniżej typowego progu alarmowego $|r| > 0.85$.



Rys. 3. MLR-4: wartości eksperymentalne vs przewidywane dla TS i VS.



Rys. 4. MLR-4: wykres reszt.

6. Domeny stosowalności dla true external validation

Domenę stosowalności oceniono przez min-max check dla deskryptorów użytych w modelu, najbliższą odległość od zbioru TS po standaryzacji oraz leverage. Dla MLR-4 liczba deskryptorów $p = 4$, liczba obiektów TS = 24, więc próg ostrzegawczy $h^* = 3*(p+1)/n = 0.625$.

Tabela 5. Ocena AD dla MLR-4.

Związek	log D	$\epsilon\alpha$	$\epsilon\beta$	V'	Min dist.	h	h*	Ocena
Naftalen	3.300 OK	0.255 OK	0.296 OK	1.109 poza	1.274	0.428	0.625	ostrożna, ale leverage OK
Nitrobenzen	1.850 OK	0.291 poza	0.327 OK	0.738 poza	4.159	1.948	0.625	poza domeną wg leverage

Naftalen ma dobrą zgodność z wartością referencyjną i leverage poniżej h^* , ale jego V' jest poniżej zakresu TS, dlatego predykcja jest wiarygodna z ostrożnym komentarzem. Nitrobenzen ma bardzo dobrą zgodność liczbową z wartością referencyjną, ale $\epsilon\alpha$ i V' są poza zakresem TS, minimalna odległość od zbioru uczącego jest duża, a leverage $h = 1.948$ przekracza $h^* = 0.625$. Dlatego predykcję nitrobenzenu należy raportować jako zgodną z referencją, ale poza formalną domeną stosowalności MLR-4.

7. Interpretacja modeli kNN i Decision Tree

Dla kNN dobrano $k = 2$, weights = uniform i metrykę euklidesową. Model opiera się tylko na log D, więc jest prosty, ale działa jako lokalna interpolacja i nie dostarcza mechanistycznego równania. W walidacji referencyjnej daje słabe wyniki dla obu związków external.

Dla drzewa decyzyjnego zastosowano max_depth = 4 i min_samples_leaf = 2. Ważność cech wynosiła około 0.935 dla log D oraz 0.065 dla π , więc model w praktyce tnie przestrzeń głównie według hydrofobowości. Drzewo trafia nitrobenzen, ale dramatycznie myli naftalen, dlatego nie powinno być modelem końcowym.

8. Ocena według zasad OECD

1. Zdefiniowany endpoint: LogKd / LogKda adsorpcji związków organicznych na PP.
2. Przezrysty algorytm: końcowy model to MLR z czterema deskryptorami, standaryzacją dopasowaną wyłącznie na TS i jawnie podanym równaniem. kNN i Decision Tree użyto jako modele porównawcze.
3. Dziedzina stosowalności: model jest wiarygodny głównie dla związków podobnych do zbioru TS. Naftalen jest blisko domeny modelu; nitrobenzen jest liczbowo zgodny z referencją, ale poza formalną domeną stosowalności MLR-4.
4. Jakość dopasowania, odporność i predykcyjność: MLR-4 ma $R^2_{TS} = 0.945$, $Q^2_{CV} = 0.853$, $Q^2_{Ext} = 0.945$, $RMSE_{Ext} = 0.312$ i $MAE_{Ext} = 0.234$. Brak typowego przeuczenia w relacji TS-VS, ale Q^2_{CV} jest niższe niż w MLR-2.
5. Interpretacja mechanistyczna: dominująca dodatnia rola log D jest zgodna z hydrofobowym charakterem PP. Ujemna rola $\epsilon\beta$ jest zgodna z konkurencją oddziaływań z fazą wodną. Pozostałe dwa deskryptory pełnią raczej funkcję korekcyjną i nie powinny być nadinterpretowane.

9. Porównanie z literaturą

Punktem odniesienia dla prostszego modelu jest praca Li et al. 2020, w której dla PP/seawater zaproponowano równanie $\log Kd = 0.751 \cdot \log D - 19.323 \cdot \epsilon\beta + 6.735$ oraz raportowano dobre statystyki modelu QSPR. Otrzymany w tym projekcie MLR-2 jest bardzo zbliżony do tego modelu, co wzmacnia wiarygodność pary deskryptorów log D + $\epsilon\beta$. Rozszerzenie do MLR-4 poprawia zgodność z referencyjnymi wartościami true external, ale oddala model od najprostszego opisu literaturowego.

Dla eksperymentalnych porównań naftalenu i nitrobenzenu najbliższa literatura obejmuje badanie Wang et al. 2019 dotyczące sorpcji fenantrenu, nitrobenzenu i naftalenu na mezoplastikach i mikroplastikach. Autorzy wskazują, że talc-filled PP microplastics wykazywały szczególnie silną sorpcję nitrobenzenu i naftalenu ze względu na obecność talku i wysoką powierzchnię właściwą. Nie jest to jednak identyczny materiał i endpoint jak w modelu QSPR, dlatego wartości eksperymentalne z takich prac powinny służyć jako kontekst, nie jako bezpośredni target kalibracyjny.

10. Ograniczenia

Najważniejsze ograniczenie to mały zbiór danych: 35 związków, w tym nierównomierna przestrzeń chemiczna z przewagą związków chlorowanych, PAH i kilku grup związków polarnych. Rozszerzony MLR-4 ma cztery deskryptory, co nadal mieści się w rozsądnym zakresie, ale przy $n = 24$ w TS wymaga większej ostrożności niż MLR-2. Zgodność nitrobenzenu z wartością referencyjną nie znosi problemu domeny stosowalności: ten związek jest poza AD dla MLR-4 według leverage i części deskryptorów. Ponadto wartości referencyjne 3.7 i 2.5 mogą pochodzić z warunków eksperymentalnych nieidentycznych z modelowanym endpointem PP/seawater.

11. Wnioski końcowe

Po wprowadzeniu dodatkowego kryterium referencyjnego najlepszym kompromisem jest MLR-4: $\text{LogKda} = 6.5892 + 0.8083 \cdot \log D + 5.3015 \cdot \epsilon \alpha - 21.2748 \cdot \epsilon \beta - 0.4953 \cdot V'$. Model ma bardzo dobrą jakość predykcji VS i bardzo dobrą zgodność z referencjami external: 3.762 vs 3.7 dla naftalenu oraz 2.305 vs 2.5 dla nitrobenzenu. W raporcie należy jednak uczciwie podkreślić, że predykcja nitrobenzenu jest poza formalną domeną stosowalności MLR-4, więc jej zgodność z referencją nie może być przedstawiana jako pełne potwierdzenie modelu.

MLR-2 pozostaje ważnym modelem kontrolnym: jest prostszy, bardziej stabilny w CV i silnie zgodny z literaturą, ale słabo przewiduje referencyjną wartość nitrobenzenu. kNN i Decision Tree nie powinny być modelami końcowymi, ponieważ każdy z nich daje poważny błąd dla co najmniej jednego związku external albo jest mniej interpretowalny.

12. Propozycja układu prezentacji do 12 minut

- Cel projektu i endpoint LogKda - 1 min.
- Opis danych, targetu i deskryptorów - 1 min.
- Podział TS/VS i zasada braku leakage - 1 min.
- Modele: MLR-2, MLR-4, kNN, Decision Tree - 2 min.
- Tabela metryk TS/CV/VS i wybór modelu - 2 min.
- Dodatkowa walidacja referencyjna 3.7/2.5 i AE - 1.5 min.
- Równanie MLR-4 i interpretacja chemiczna - 1.5 min.
- Domena stosowalności: naftalen vs nitrobenzen - 1 min.
- Ograniczenia i końcowy wniosek - 1 min.

Bibliografia i źródła

Li M., Yu H., Wang Y., Li J., Ma G., Wei X. QSPR models for predicting the adsorption capacity for microplastics of polyethylene, polypropylene and polystyrene. Scientific Reports 10, 14597 (2020). DOI: 10.1038/s41598-020-71390-3.

Wang J., Liu X., Liu G. Sorption behaviors of phenanthrene, nitrobenzene, and naphthalene on mesoplastics and microplastics. Environmental Science and Pollution Research 26, 12563-12573 (2019). DOI: 10.1007/s11356-019-04735-9.

Dane wejściowe: arkusz data_qsar.xlsx, arkusz PROJEKT; wartości referencyjne external: naftalen LogKd ≈ 3.7 , nitrobenzen LogKd ≈ 2.5 , użyte wyłącznie po zbudowaniu modeli.

Aneks metodologiczny: czy wartości 3.7 i 2.5 można uzyskać na dwóch deskryptorach?

Po dodaniu referencyjnych wartości external validation należy oddzielić dwa różne kryteria: trafienie wartości liczbowych dla dwóch nowych związków oraz stabilność modelu QSPR ocenianą na zbiorze uczącym, w walidacji krzyżowej i na VS. Wartości referencyjne dla naftalenu (LogKd około 3.7) i nitrobenzenu (LogKd około 2.5) nie były używane do trenowania, skalowania, selekcji deskryptorów ani strojenia modeli. Zostały użyte wyłącznie po zbudowaniu modeli, jako dodatkowy punkt odniesienia dla predykcji true external validation.

Przeliczenie wariantów MLR z dwoma deskryptorami pokazuje, że liczbowo można zbliżyć się do wartości 3.7/2.5 na prostym modelu 2D, ale nie zawsze jest to model metodologicznie najlepszy. Najlepszy statystycznie model dwudeskryptorowy, czyli MLR-2 z deskryptorami logD oraz $\epsilon\beta$, bardzo dobrze opisuje TS, CV i VS, jednak zaniża predykcję dla nitrobenzenu. Z kolei model logD + V' daje znacznie lepszą zgodność external dla nitrobenzenu, ale wyraźnie słabszą walidację krzyżową i zewnętrzną VS, dlatego nie powinien automatycznie zastępować modelu głównego.

Model MLR 2D	Q ² CV	Q ² Ext VS	RMSEExt VS	Naftalen pred./AE	Nitrobenzen pred./AE	Ocena metodologiczna
logD + $\epsilon\beta$	0.897	0.922	0.372	3.492 / 0.208	1.725 / 0.775	Najlepszy i najbardziej stabilny model 2D, ale słaba zgodność dla nitrobenzenu.
logD + V'	0.723	0.586	0.858	3.418 / 0.282	2.538 / 0.038	Najlepsza zgodność external spośród modeli 2D, ale słabsza predykcyjność VS i CV.
logD + Mw'	0.731	0.741	0.679	4.040 / 0.340	2.969 / 0.469	Akceptowalny naftalen, ale słaba zgodność nitrobenzenu i gorszy wynik od MLR-2.

Wniosek z tej kontroli jest następujący: nie można stwierdzić, że na dwóch deskryptorach w ogóle nie da się uzyskać predykcji bliskich 3.7 i 2.5. Da się to uzyskać liczbowo, na przykład wariantem logD + V', który daje bardzo dobrą zgodność dla nitrobenzenu i akceptowalną zgodność dla naftalenu. Jednak ten wariant ma wyraźnie gorsze parametry walidacyjne niż MLR-2 logD + $\epsilon\beta$, szczególnie Q²CV i Q²Ext dla VS. Oznacza to, że poprawa zgodności z dwoma punktami external odbywa się kosztem ogólnej stabilności predykcyjnej modelu.

Dlatego w raporcie należy traktować MLR-2 jako ważny model kontrolny i literaturowo uzasadniony punkt odniesienia, ale nie jako model w pełni wystarczający do przewidywania nitrobenzenu. Rozszerzony model MLR-4 pozostaje lepszym kompromisem po uwzględnieniu dodatkowego kryterium referencyjnego, ponieważ zachowuje bardzo dobrą predykcyjność VS i jednocześnie daje predykcje external bliskie wartościom referencyjnym: około 3.762 dla naftalenu i 2.305 dla nitrobenzenu. Takie podejście jest metodologicznie bezpieczniejsze niż ręczne korygowanie predykcji lub wybór modelu wyłącznie dlatego, że dobrze trafia dwa związki zewnętrzne.

Konkluzja praktyczna: wynik 3.7/2.5 na dwóch deskryptorach jest możliwy w sensie liczbowym, ale nie jest najlepszym kryterium wyboru modelu. Model końcowy powinien być wybierany dopiero po łącznej ocenie: TS, CV, VS, błędów external, domeny stosowalności, braku przeuczenia i interpretowalności chemicznej.